

Informe Técnico - KickoffAgent

KickoffAgent

Plataforma de Agente Inteligente para Levantamiento, Formulación Ágil y Consulta Trazable de Proyectos de Software

Integrantes	Génesis Valdebenito & Héctos Torres
Repositorio	 GitHub - GenesisValdebenito/KickoffAgent
Docente	Francisco Andrés Macaya
Entrega	Evaluación Parcial N°1
Propósito	Diseño de solución con LLM y RAG
Fecha	09/09/2026 18:59

 Durante el desarrollo del proyecto se utilizó como apoyo el uso de IA. Con el propósito de estructurar el informe, diseño y justificación de prompts, retroalimentación de arquitectura. Claude (Antropic). Para la implementación del script Python, integración de librerías y refactorización del repositorio. Antrigravity (asistente de código). Todas las ideas, análisis técnicos, justificaciones de diseños y reflexiones personales fueron desarrolladas por el equipo. Todo el contenido generado por IA fue revisado, validado y adaptado por los integrantes.

1. Contexto y problema organizacional

En el contexto de consultoría en Tecnologías de la Información (TI) y el desarrollo de software corporativo, la fase de descubrimiento o kickoff representa el hito más determinante para el éxito o fracaso de una iniciativa. Durante este periodo, las organizaciones se enfrentan al desafío de procesar grandes volúmenes de información heterogénea proveniente de entrevistas a stakeholders, minutas de reunión desestructuradas, expedientes de licitación y especificaciones técnicas preliminares.

Síntesis del problema: La necesidad urgente de una solución agéntica que garantice tres pilares: (1) cero alucinaciones numéricas en viabilidad financiera, (2) trazabilidad estricta y auditable hacia las fuentes documentales, y (3) automatización rigurosa del paso desde el levantamiento estratégico hasta el backlog ágil.

2. Objetivo General

Diseñar, implementar y validar KickoffAgent, una plataforma agéntica inteligente basada en la orquestación de LLMs, un pipeline RAG semántico local y herramientas deterministas de cálculo financiero mediante Tool Calling, orientada al levantamiento estratégico (FODA/PESTEL), formulación formal de requerimientos bajo el estándar IEEE 830, estructuración ágil de backlog y consulta trazable de proyectos de software.

2.2 Objetivos específicos

- Diseñar y justificar una arquitectura modular de micro-prompts especializados con roles analíticos senior, contratos JSON estrictos y directivas anti-alucinación explícitas.
- Construir un pipeline RAG local utilizando FastEmbed (BAAI/bge-small-en-v1.5) y ChromaDB persistente, garantizando soberanía de datos y baja latencia de inferencia.
- Elaborar la representación estructural y el flujo de control end-to-end del sistema, formalizando la interacción entre los tres módulos con sus compuertas de decisión.
- Implementar la herramienta matemática calcular_metricas_financieras basada en numpy-financial y validación tipada con Pydantic, erradicando alucinaciones en cálculos de VAN, TIR, ROI y PRI.
- Establecer directivas de grounding estricto con citas obligatorias de fuentes, respuestas de rechazo ante falta de contexto y validación empírica en casos reales de consultoría TI.

3. Fuentes de datos

KickoffAgent procesa un corpus documental heterogéneo representativo del ciclo inicial de consultoría tecnológica. Las fuentes se gestionan con metadatos que aseguran trazabilidad biunívoca en todo el pipeline:

Tipo de documento	Formato	Contenido principal	Metadatos
Actas de reunión de kickoff	PDF / texto estructurado	Presupuestos, flujos de caja, tasas de descuento, visión gerencial	{source: 'Acta_Reunion_01.pdf', fase: 'finanzas'}
Especificación técnica IEEE 830	PDF / Markdown	RF base, estándares de arquitectura, protocolos de autenticación	{source: 'Especificacion_IEEE830.pdf', fase: 'requerimientos'}

Cuestionario de levantamiento	Formulario / texto plano	FODA, PESTEL, factores regulatorios externos	{source: 'Cuestionario_Levantamiento.json', fase: 'estrategia'}
Evidencias documentales de apoyo	PDFs de políticas / SLA	Tiempos de respuesta, disponibilidad, normativas legales	{source: 'Anexo_SLA_Seguridad.pdf', fase: 'evidencia'}

4. Solución propuesta y arquitectura

La solución articula una arquitectura modular desacoplada en tres módulos funcionales, diseñada para transformar insumos desestructurados en artefactos formales de ingeniería de software y decisiones financieras verificables.

4.1 Módulos del sistema

Módulo	Componentes principales	Entradas / Salidas
Módulo 1: Agente de levantamiento estratégico	Síntesis FODA & PESTEL (Prompt 00A), Clasificador de evidencia (Prompt 00B), Generador de documento de antecedentes	Input: cuestionario + evidencias. Output: documento estructurado antecedentes & necesidades
Módulo 2: Agente de backlog y planificación ágil	Extractor RF/RNF IEEE 830 (Prompt 01), Generador de backlog épicas→historias→sprints (Prompt 02), Persistencia en tablero ágil	Input: doc antecedentes & necesidades. Output: backlog formalizado, Fibonacci, asignación de sprints
Módulo 3: Módulo RAG y orquestación conversacional	Orquestador LangGraph + Groq LPU, ChromaDB + FastEmbed, Tool Calling financiero (numpy-financial), Evaluador de fidelidad	Input: consultas en lenguaje natural. Output: respuestas grounded con citas y dictamen financiero

4.2 Diagrama de arquitectura

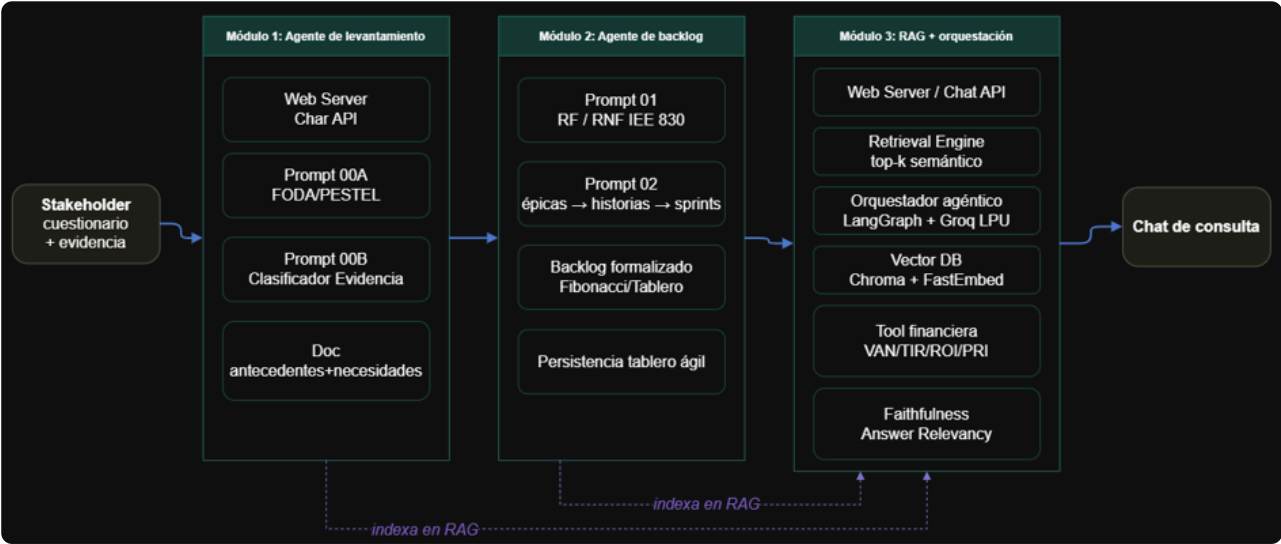


Figura 1. Arquitectura de solución KickoffAgent. Las flechas azules continuas representan el flujo de transformación principal; las líneas moradas punteadas representan la indexación semántica en ChromaDB; la caja ámbar representa la tool determinista financiera conectada al orquestador LangGraph.

4.3 Flujo de control end-to-end




Figura 2. Flujo de control con bifurcaciones y retroalimentación. Incluye dos compuertas de decisión: clasificación de evidencia de apoyo y validación de suficiencia de RF/RNF con loop de ajuste al cuestionario.

5. Prompts optimizados

La ingeniería de prompts en KickoffAgent se estructura bajo el principio de micro-responsabilidad encadenada: cada prompt tiene un único objetivo, un rol profesional explícito, directivas estrictas de no-alucinación y un contrato de salida JSON para garantizar

interoperabilidad programática entre etapas. Los textos completos de cada prompt se encuentran en la carpeta `prompts/` del repositorio.

5.1 Prompt 01 — Extracción y síntesis FODA/PESTEL

Etapas: Módulo 1 — Agente de levantamiento estratégico

Archivo: `prompts/prompt_01.md`

El modelo adopta el rol de consultor estratégico senior. A partir de las respuestas del cuestionario de levantamiento, organiza la información en un esquema canónico FODA (Fortalezas, Oportunidades, Debilidades, Amenazas) y PESTEL (Político, Económico, Social, Tecnológico, Ecológico, Legal), exigiendo arrays vacíos ante información no respaldada — nunca infiere ni completa con conocimiento general externo. La salida es JSON estricto con los campos: `foda`, `pestel`, `antecedentes` y `necesidades`.

Justificación técnica: La restricción anti-alucinación explícita es crítica porque un FODA/PESTEL inventado se propaga y degrada tanto el documento de antecedentes como el backlog final (principio *garbage in, garbage out*). La salida JSON alimenta programáticamente al Prompt 03, por lo que cualquier campo faltante o mal tipado rompe el pipeline.

5.2 Prompt 02 — Clasificador de evidencia de apoyo

Etapas: Módulo 1 — Agente de levantamiento estratégico

Archivo: `prompts/prompt_02.md`

El modelo actúa como clasificador de documentos individuales subidos por el usuario — entrevistas, actas, benchmarking o datos de mercado. Cada documento se asigna a una o dos categorías del esquema FODA (Fortaleza, Oportunidad, Debilidad, Amenaza), PESTEL (Político, Económico, Social, Tecnológico, Ecológico, Legal), Antecedentes, Necesidades u Otro. La salida es JSON con los campos `documento`, `categorias` y `resumen_breve`.

Justificación técnica: Se separa del Prompt 01 porque clasificar un documento individual es una tarea distinta a sintetizar el conjunto de respuestas del cuestionario — modularizarlos permite procesar documentos en paralelo sin degradar la precisión. La metadata de categoría resultante enriquece el indexado en ChromaDB, mejorando la precisión de las búsquedas semánticas posteriores.

5.3 Prompt 03 — Extracción de requerimientos funcionales y no funcionales (IEEE 830)

Etapas: Módulo 2 — Agente de backlog y planificación ágil

Archivo: `prompts/prompt_03.md`

El modelo adopta el rol de analista senior de requerimientos de software. Transforma el documento de antecedentes y necesidades en una especificación estructurada bajo el estándar

IEEE 830: problemática, objetivos, requisitos funcionales con criterio de verificación objetivo y requisitos no funcionales medibles y verificables. Asigna identificadores formales secuenciales (RF-01, RF-02, RNF-01). La directiva anti-alucinación prohíbe explícitamente agregar requisitos no sustentados en el documento de entrada. La salida es JSON estricto.

Justificación técnica: Salida JSON porque alimenta directamente al Prompt 04 de forma programática. Un error en esta etapa se propaga a todo el backlog generado posteriormente — es el eslabón más crítico del pipeline de transformación.

5.4 Prompt 04 — Desagregación ágil en épicas, historias y sprints

Etapas: Módulo 2 — Agente de backlog y planificación ágil

Archivo: `prompts/prompt_04.md`

El modelo actúa como Product Owner y Agile Lead. Transforma cada requisito funcional en historias de usuario con sintaxis canónica ("Como [rol], quiero [acción], para [beneficio]"), incorpora criterios de aceptación BDD (Given / When / Then), asigna story points en escala Fibonacci (1, 2, 3, 5, 8, 13) con justificación de la estimación, y organiza sprints balanceados con capacidad objetivo de 20 puntos respetando dependencias implícitas entre requisitos.

Justificación técnica: La descomposición en pasos numerados (chain-of-thought guiado) evita omisiones en una tarea compleja de una sola pasada. Exigir justificación de la estimación da trazabilidad de decisiones al equipo humano que revisa el resultado. La prohibición explícita de agregar funcionalidades no sustentadas en los requisitos de entrada garantiza que el backlog sea auditable.

5.5 Prompt 05 — Respuesta RAG anclada en evidencia con grounding estricto

Etapas: Módulo 3 — Módulo RAG y orquestación conversacional

Archivo: `prompts/prompt_05.md`

El modelo adopta el rol de consultor senior de proyecto. Responde únicamente con base en los fragmentos recuperados por el Retriever, citando siempre el identificador del documento fuente en una sección **Fuentes:** obligatoria al final de cada respuesta. Ante ausencia de contexto suficiente, emite una respuesta de rechazo formal indicando qué información falta — nunca inventa ni completa con conocimiento general. La instrucción de ordenar la evidencia más relevante al inicio y cierre del contexto aplica el hallazgo de Liu et al. (2024): el desempeño del LLM forma una curva en U según la posición de la información relevante en el contexto, degradándose cuando queda enterrada en el medio. Las operaciones de cálculo financiero se delegan siempre a la tool determinista `calcular_metricas_financieras` — nunca se calculan manualmente en el prompt.

Justificación técnica: El patrón de rechazo explícito mejora Faithfulness al eliminar respuestas inventadas. La sección **Fuentes:** obligatoria habilita trazabilidad auditable, esencial en contextos de consultoría donde cada decisión debe respaldarse en documentación formal. La delegación financiera a numpy-financial garantiza cero alucinaciones numéricas en VAN, TIR, ROI y PRI.

7. Control de calidad y trazabilidad

KickoffAgent implementa dos mecanismos complementarios para garantizar respuestas confiables y auditables.

Cero alucinaciones financieras: Las métricas VAN, TIR, ROI y PRI se delegan íntegramente a la herramienta determinista `calcular_metricas_financieras` basada en numpy-financial con validación tipada Pydantic. El LLM nunca calcula — solo interpreta el resultado.

Trazabilidad documental: Cada respuesta del módulo RAG incluye obligatoriamente una sección **Fuentes:** con el identificador del documento origen. Las consultas y sus chunks recuperados quedan registrados en log, permitiendo auditoría posterior de cada decisión.

Validación empírica — resultados de ejecución:

Test 1 — Consulta RAG: Ante la pregunta por los requerimientos funcionales aprobados, el agente recuperó y citó correctamente RF-01 (OAuth2), RF-02 (exportación PDF/Excel en menos de 3 segundos) y RNF-01 (disponibilidad 99.9%), con referencia explícita a `[Especificacion_IEEE830.pdf]`.

Test 2 — Evaluación financiera: Ante la solicitud de viabilidad del proyecto, el agente extrajo los parámetros del `[Acta_Reunion_01.pdf]` y delegó el cálculo en la tool determinista, obteniendo VAN = +\$881.292,26 CLP, TIR = 13,9%, ROI = 30,83% y PRI = 3 periodos, emitiendo el dictamen: **proyecto financieramente viable**.

8. Restricciones y limitaciones

- El modelo de razonamiento opera sobre la infraestructura Groq, sujeta a límites de tasa de peticiones por minuto. Requiere conexión a internet para el servicio de inferencia.
- El cálculo de la TIR asume flujos con un único cambio de signo. En series no convencionales con múltiples cambios de signo, la herramienta captura la excepción y retorna formalmente "No convergente".
- El `chunk_size` de 700 tokens y `Top-K=3` acota el contexto recuperado a aproximadamente 2.100 caracteres. Documentos con requerimientos extensos en tablas complejas pueden requerir reensamblado previo.

- Las credenciales corporativas (GROQ_API_KEY) están aisladas mediante archivos .env no versionados. Los embeddings y la base vectorial se ejecutan 100% de forma local, resguardando la propiedad intelectual del cliente.
- El pipeline actual no incluye evaluación automática de Faithfulness y Answer Relevancy mediante RAGAS — se contempla como trabajo futuro para la siguiente iteración.

9. Conclusiones

9.1 Conclusiones del proyecto

KickoffAgent valida con éxito la efectividad de los sistemas agénticos modernos aplicados a la ingeniería de software y la consultoría tecnológica. La delegación de operaciones matemáticas en librerías deterministas mediante Tool Calling tipado demostró ser la única estrategia viable para certificar métricas financieras críticas en contextos corporativos. La segmentación de responsabilidades en micro-prompts especializados superó ampliamente a los prompts monolíticos tradicionales, y la combinación de FastEmbed y ChromaDB local eliminó costos recurrentes de embeddings manteniendo excelente capacidad de recuperación semántica.

9.2 Reflexión personal — Genesis Valdebenito

Mi reflexión con el proyecto de trabajar diseñar una solución con LLM y RAG es genial. Porque me permite explorar los nuevos avances de la tecnología, poder buscar tareas difíciles y resolverlas mediante un agente entrenado. Poder sacar el mayor provecho y facilitar tareas complejas que requieren mayor inteligencia. Reducir el tiempo de planificación y resolución de una tarea. Al desarrollar este agente, comprendí que no es tan solo usar un agente, si no asegurar la calidad y certeza de sus respuestas. Creo que lo más complejo del desarrollo fue el informe. Debido a que tenemos que dejar en evidencia lo desarrollado y cumplir con la rúbrica.

9.3 Reflexión personal — Héctor Torres

Mi reflexión con este proyecto fue trabajar en un agente, algo nuevo para mi, ya que el tema me interesa mucho porque hoy en día se trabaja mucho con estos agentes ya que pueden hacer tareas que para uno a veces puede ser un poco tedioso y repetitivo, encuentro que manejar estas tecnologías y sacarle provecho es primordial en todo informático porque la competencia ya está usando estas tecnologías que te alivianan mucho el trabajo y en productividad vs estos agentes nos quedaremos atrás si no los usamos, fue un buen desafío, pero con mi compañera pudimos hacer un proyecto acorde a lo que exige la rúbrica.

10. Referencias

Chase, H. (2023). LangChain: Building applications with LLMs through composability. GitHub repository. [GitHub - langchain-ai/langchain: The agent engineering platform.](https://github.com/langchain-ai/langchain)

IEEE Computer Society. (1998). IEEE recommended practice for software requirements specifications (IEEE Std 830-1998). Institute of Electrical and Electronics Engineers.

<https://doi.org/10.1109/IEEESTD.1998.88286>

Lewis, P., Perez, E., Piktus, A., Petroni, F., Karpukhin, V., Goyal, N., Küttler, H., Lewis, M., Yih, W., Rocktäschel, T., Riedel, S., & Kiela, D. (2020). Retrieval-augmented generation for knowledge-intensive NLP tasks. *Advances in Neural Information Processing Systems*, 33, 9459–9474.  [Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks](#)

Liu, N. F., Lin, K., Hewitt, J., Paranjape, A., Bevilacqua, M., Petroni, F., & Liang, P. (2024). Lost in the middle: How language models use long contexts. *Transactions of the Association for Computational Linguistics*, 12, 157–173.  [Lost in the Middle: How Language Models Use Long Contexts](#)

Qwen Team. (2024). Qwen2 technical report. arXiv preprint arXiv:2407.10671.  [Qwen2 Technical Report](#)

Schwaber, K., & Sutherland, J. (2020). The Scrum guide: The definitive guide to Scrum: The rules of the game. [Scrum.org](https://www.scrum.org). [Home](#) | [Scrum Guides](#)

Wang, L., Ma, C., Feng, X., Zhang, Z., Hao, J., & Chen, W. (2024). A survey on large language model based autonomous agents. *Frontiers of Computer Science*, 18(6), 186345. <https://doi.org/10.1007/s11704-024-40231-1>

Xiao, S., Liu, Z., Zhang, P., & Muennighoff, N. (2023). C-pack: Packaged resources to advance general Chinese embedding (BAAI/bge models). arXiv preprint arXiv:2309.07597.  [C-Pack: Packaged Resources For General Chinese Embeddings](#)